Komprese obrazů

Václav Hlaváč

České vysoké učení technické v Praze
Český institut informatiky, robotiky a kybernetiky
160 00 Praha 6, Jugoslávských partyzánů 1580/3
http://people.ciirc.cvut.cz/hlavac, vaclav.hlavac@cvut.cz
také z Centra strojového vnímání, http://cmp.felk.cvut.cz

Poděkování: Tomáš Svoboda, Jan Kybic

Osnova přednášky:

- Redundance a irelevance; 1D a 2D.
- Kroky komprese obrazu.
- Entropie a komprese.
- Optimální kódování.
- Komprese segmentovaných obrazů.
- Ztrátová komprese v prostoru obrazů.
- Komprese v transformovaném prostoru. Např. JPEG, Wavelets komprese.

Komprese obrazů, úvod

- Cíl: Zmenšení množství dat potřebných k reprezentaci obrazu. Spotřebované množství paměti se měří například v bitech.
- Použití: Pro přenos a uchování dat.
- Proč se liší komprese 2D obrazů od komprese 1D dat?

- Digitalizovaný obraz se chápe jako dvojrozměrná struktura (matice) náhodných vzorků.
- Matematicky řečeno: Cílem je převést matici jasů (nebo 3 matice s barevnými složkami) do jiné reprezentace, v níž jsou obrazová data méně statisticky závislá (zhruba řečeno, méně korelovaná).

Proč je možná komprese obrazů?

- Obrazy nejsou náhodné. Nejsou většinou pouze náhodným šumem.
- V obrazech je nadbytečnost (redundance). Hodnotu obrazové funkce lze z hodnot v okolí předpovídat.
- Hodnoty obrazové funkce nejsou rozděleny rovnoměrně.
- Mezi hodnotami obrazové jsou plošné závislosti (korelace), velmi často se projevují lokálně, někdy i globálně (např. u některých textur).
- U barevných obrazů jsou mezi jejich jednotlivými barevnými kanály statistické závislosti.
- Ne všechny detaily jsou obrazech potřebné, když je bude pozorovat člověk. Vizuální subsystém člověka mnohé detaily není schopen vnímat.

Možné čtení

- Anil Jain: “Fundamentals of Digital Image Processing”, 1989.
- Milan Šonka, Václav Hlaváč, Roger Boyle: “Image Processing, Analysis, and Machine Vision”, 2015, 4th edition.
- Tomáš Svoboda, Jan Kybic, Václav Hlaváč: “Image Processing, Analysis, and Machine Vision, A MATLAB Companion”, 2007. `http://visionbook.felk.cvut.cz`
- Petr Vysoký: C. E. Shannon - průkopník informačního věku, Vesmír, svazek 83, srpen 2004, str. 472-473.

Podvzorkování, motivace pro kompresi obrázků

- Snížení prostorového rozlišení obrazu.
- Jednoduchá, ztrátová metoda komprese, která se obvykle hodí pro web nebo zobrazování na monitoru s omezeným prostorovým rozlišením.
- Lze vylepšit pokročilejší interpolací, např. pomocí B-splajnů.

Snížení rozlišení, příklad (1)

Original size, 3456×5184, $859\,\mathrm{kB}$ (stored as JPEG with quality 75).

Snížení rozlišení, příklad (2)

Downsampled $2\times$, 1728×2592, 237 kB.

Snížení rozlišení, příklad (3)

Downsampled $4\times$, 864×1296, 75 kB.

Snížení rozlišení, příklad (4)

Downsampled $8\times$, 432×648, 27 kB.

Snížení rozlišení, příklad (5)

Downsampled $16\times$, 216×324, 10 kB.

Snížení rozlišení, příklad (6)

Downsampled $16\times$, 216×324, 10 kB, bicubic interpolation.

Snížení rozlišení, příklad (7)

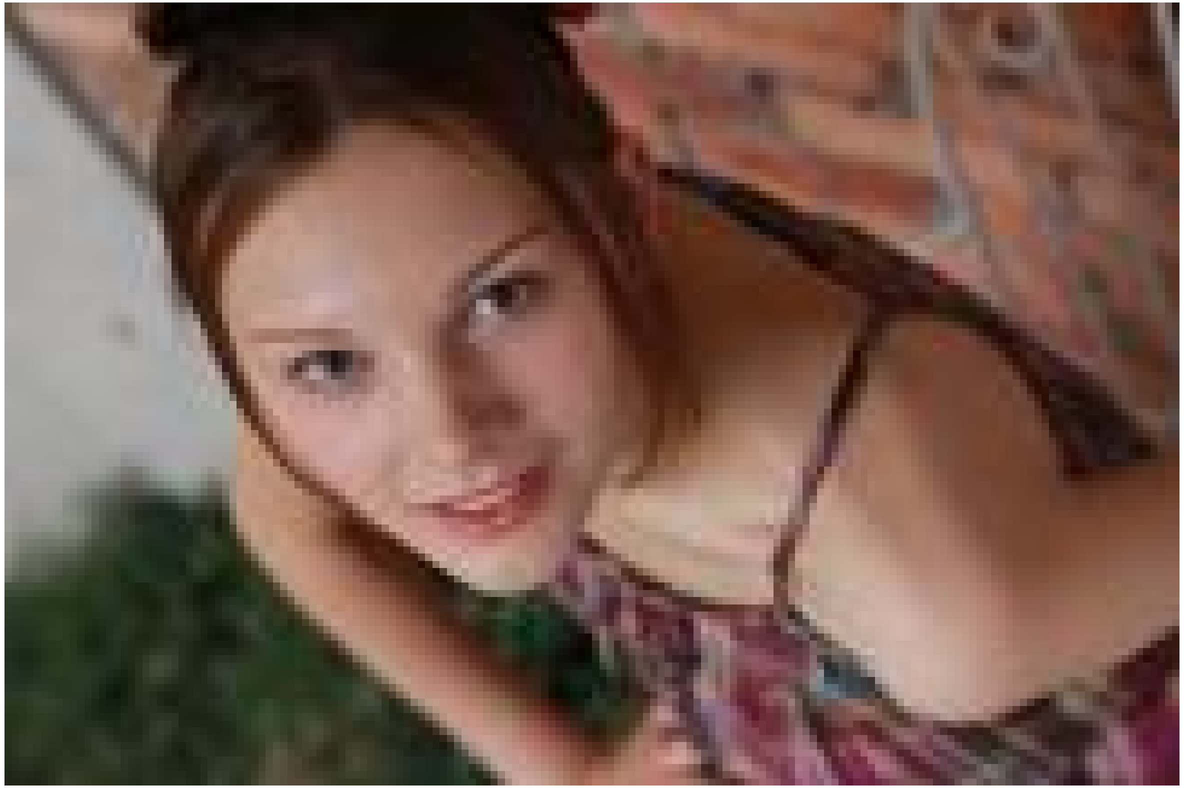

Downsampled $32\times$, 108×162, 4.2 kB.

Snížení rozlišení, příklad (8)

Downsampled $32\times$, 108×162, 4.2 kB, bicubic interpolation.

Redundance, irelevance

- Redundance v kódování
  - Základní princip: častěji se opakující symbol se kóduje kratším kódovým slovem než řídčeji se opakující symbol.
  - Optimální kódování: Huffmanovo a aritmetické kódování.
- Redundance mezi pixely, modeluje se a jen residuum vůči modelu se kóduje, protože má menší rozptyl. Různé modely, např.:
  - Lineární integrální transformace obrazu, např. Fourierova, kosinová či vlnková.
  - Prediktivní modely, např. lineární kombinace několika předchozích vzorků.
  - Úsporné algoritmy generování obrazu, např. fraktální.
- Irelevance z hlediska vnímání člověkem
  - Nezobrazit např. všechny jasové úrovně, barvy nebo frekvence (obvykle vysoké).

Rozdělení metod komprese obrazů

1. Založené na interpretaci dat $\Rightarrow$ je potřebná segmentace obrazu.
   - Metody jsou závislé na sémantice dat.
   - Dosahuje se nejvyšších kompresních poměrů.
   - Dekomprese nezíská původní obraz zcela.
2. Bez interpretace dat $\Rightarrow$ odstranění redundantní a irelevantní informace.
   - Lze použít na libovolný obraz, a to bez ohledu na jeho sémantiku.
   - Využívá se statistických nadbytečností v obraze a (případně) irelevance některé informace pro lidské vnímání.

Dvě třídy metod bez interpretace – ztrátové a bezeztrátové

Dvě velké třídy používaných postupů:

1. Bezeztrátové metody, odstraňují redundanci.
   - Odstraňují pouze statistickou nadbytečnost.
   - Umožňují úplnou rekonstrukci výchozího signálu/obrazu.
2. Ztrátové metody, odstraňují irelevantní informaci.
   - Nevratně odstraňují část informace, která má v daném kontextu malý význam (např. vysoké frekvence, jasové detaily nepostřehnutelné lidským okem).
   - Umožňují pouze částečnou rekonstrukci výchozího signálu/obrazu.

Komprese obrazu a jeho zpětná rekonstrukce

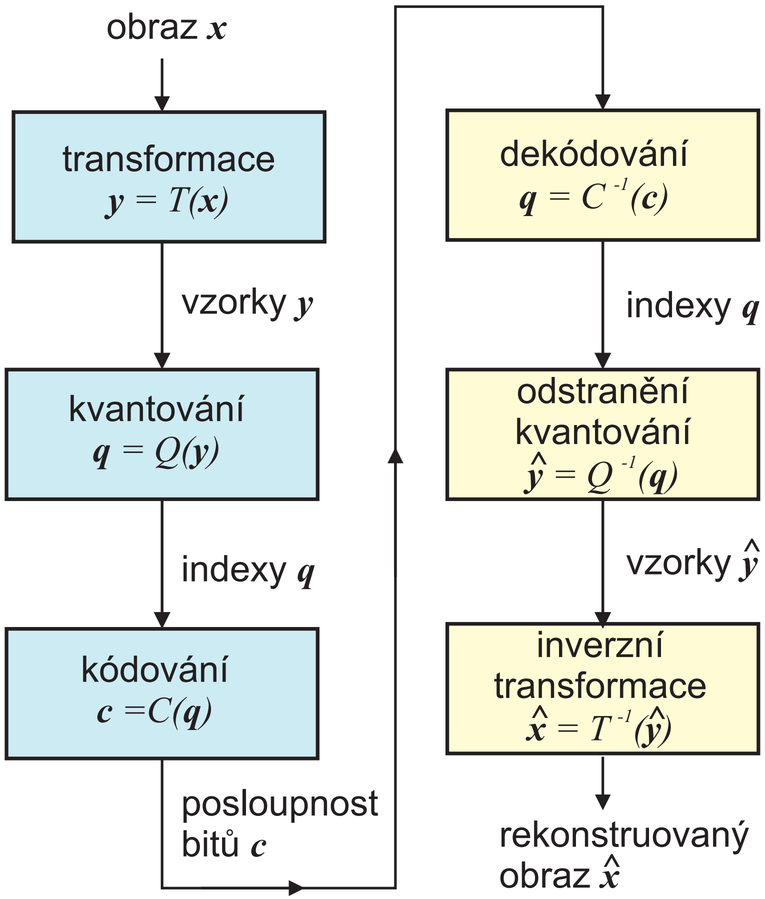

- Transformace T odstraňuje redundanci a je obvykle invertovatelná.

  Např.: kosínová transformace, kódování úseky řádků (RLE).

- Kvantování Q odstraňuje irelevanci a není invertovatelné.

  Např.: Zanedbání koeficientů kosínové transformace odpovídajících vysokým frekvencím.

- Kódování C a dekódování C^{-1} je invertovatelné a bezeztrátové.

Teorie informace a redundance

- Entropie ve fyzice je měrou energie soustavy, která není k dispozici k vykonání práce. Jelikož práci lze získat "z řádu soustavy", je entropie měrou neuspořádanosti soustavy. Souvisí s druhou termodynamickou větou.
- Pojem zavedl v roce 1850 německý fyzik Rudolf Clausius (1822-1888, jeden ze zakladatelů termodynamiky).

Entropie v teorii informace, Claude Shannon, 1948

$$H_e = -\sum_i p_i \log_2 p_i \quad \text{[bitů]}\ ,$$

kde p_i je pravděpodobnost i-tého symbolu ve zprávě.

Entropie, dva příklady

Nechť jsou ve zprávě jen dva znaky a, b.

Příklad 1 $p(\mathsf{a}) = p(\mathsf{b}) = \frac{1}{2}$

$$H = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = \left(\frac{1}{2}\cdot 1 + \frac{1}{2}\cdot 1\right) = 1$$

Příklad 2 $p(\mathsf{a}) = 0,99;\ p(\mathsf{b}) = 0,01$

$$\begin{aligned} H &= -\left(0,99\log_2 0,99 + 0,01\log_2 0,01\right) \\ &= -\left(0.99\cdot(-0,0145) + 0,01\cdot(-6,6439)\right) \\ &= 0,0144 + 0,0664 = 0,0808 \end{aligned}$$

Entropie pro šedotónový obraz

Nechť obraz má G jasových úrovní, $k = 0 \ldots G-1$ s pravděpodobnostmi $P(k)$.

$$\text{Entropie} \quad H_e = -\sum_k P(k) \log_2 P(k) \quad \text{[bitů]} \,,$$

Nechť b je nejmenší počet bitů, kterým lze reprezentovat počet kvantizačních úrovní.

$$\text{Informační redundance} \qquad r = b - H_e \,.$$

Odhad entropie z histogramu obrazu

Nechť $h(k)$, $0 \leq k \leq 2^b - 1$ a M, N jsou rozměry obrazu.

$$\text{Odhad pravděpodobnosti} \quad \hat{P} = \frac{h(k)}{M\,N}\,.$$

$$\text{Odhad entropie} \quad \hat{H}_e = -\sum_{k}^{2^b-1} \hat{P}(k) \log_2 \hat{P}(k) \quad [\text{bitů}]$$

Poznámka:

Odhad entropie je příliš optimistický. Ve skutečnosti je entropie nižší, protože mezi jasy jednotlivých pixelů obrazu existují statistické závislosti (redundance).

Ilustrace redundance mezi pixely

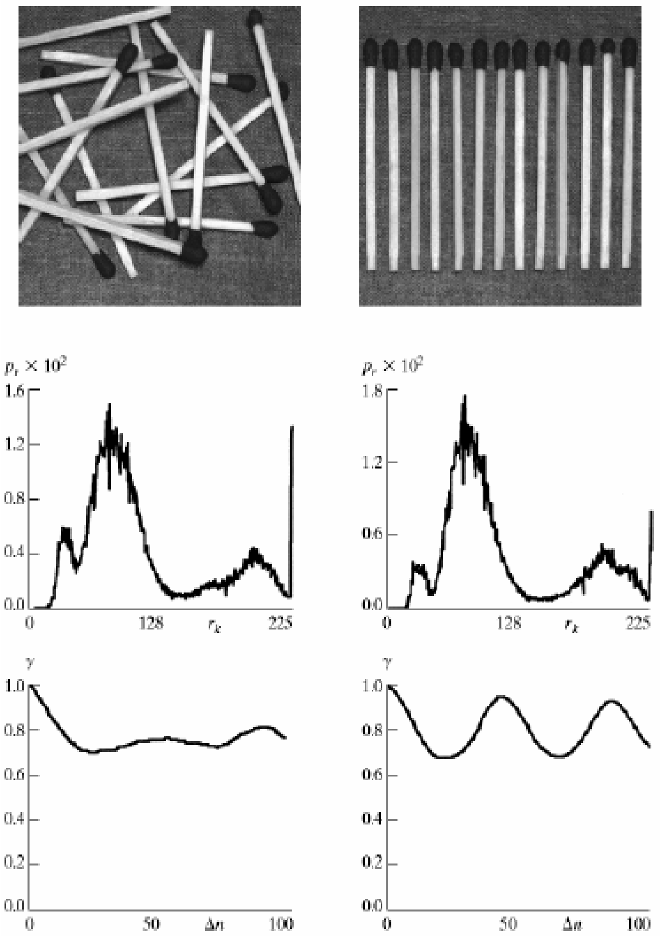

Histogram

Normalizovaná autokorelace

Poděkování: R.C. Gonzalez, R.E. Woods: Digital Image Processing, 2nd Edition, 2002, p. 415

Tři definice kompresního poměru

1. Na základě redundance (měřené entropií) $K = \frac{b}{\hat{H}_e}$
2. Na základě úspory paměti

$$\kappa = \frac{n_1}{n_2} = \frac{\text{délka zprávy před kompresí}}{\text{délka zprávy po kompresi}}$$

3. Relativní úspora paměti $R = 1 - \frac{1}{\kappa}$

Příklad 1: $n_1 = n_2 \Rightarrow \kappa = 1,\ R = 0.$

Příklad 2: $n_1 : n_2 = 10 : 1 \Rightarrow \kappa = 10,\ R = 0,9 = 90\%.$

Ohodnocování věrnosti komprese

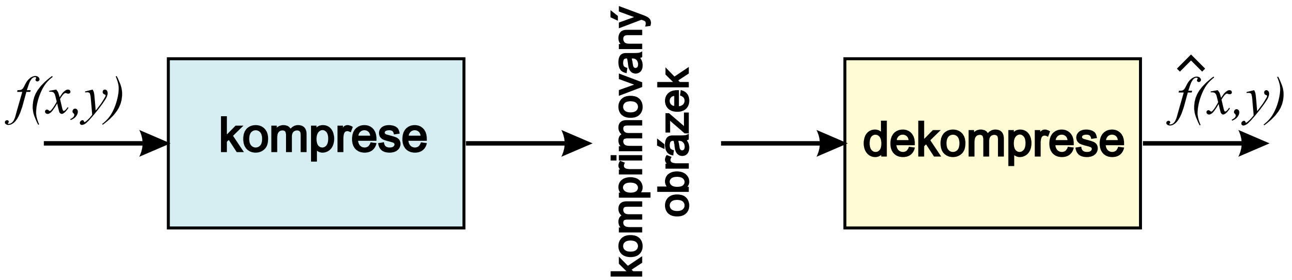

- Rekonstruovaný obraz (odhad) $\hat{f}(x,y) = f(x,y) + e(x,y)$, kde $f(x,y)$ je výchozí obrázek a $e(x,y)$ je chyba rekonstrukce (také residuum) po kompresi.
- Zde se zkoumá otázka: Jak blízko jsou si $f(x,y)$ a $\hat{f}(x,y)$?
- Kritéria pro ohodnocování věrnosti komprese:
  - Subjektivní: závisí na lidském pozorovateli, používané v televizi; snadná a prakticky používaná metoda je diferenční obrázek.
  - Objektivní: počítají se matematicky. Snaha nahradit subjektivní metody.

Měření ztrátovosti komprese

Nechť $u_1, \dots, u_n$ je výchozí posloupnost a $u_1^{'}, \dots, u_n^{'}$ ztrátově komprimovaná posloupnost

- Středně kvadratická chyba (Mean Square Error, MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^{n} \left(u_i - u_i^{'} \right)^2$$

- Poměr signálu k šumu (Signal to Noise Ratio, SNR)

$$\text{SNR} = 10 \log_{10} \frac{P^2}{\text{MSE}^2} \, [\text{dB}] \, ,$$

kde P je interval hodnot vstupní posloupnosti,
$P = \max\{u_1, \dots, u_n\}$ - $\min\{u_1, \dots, u_n\}$.

Měření ztrátovosti komprese (2)

- Špičkový poměr signálu k šumu (Peak-Signal to Noise Ratio, PSNR)

$$\text{PSNR} = 10 \log_{10} \frac{M^2}{\text{MSE}^2} \,,$$

kde M je maximální interval hodnot vstupní posloupnosti, tj. 256 pro osmibitový vstup a 65356 pro šestnáctibitový vstup.

V praxi se používá zejména SNR a PSNR. Výraz MSE slouží jako pomocný pro definici SNR a PSNR.

Huffmanovo kódování, z roku 1952

- Vstup: symboly s pravděpodobností jejich výskytu; zpráva.
- Výstup: optimálně zakódovaná zpráva.
- Prefixový kód, tj. žádné kódové slovo nemůže být prefixem žádného jiného kódového slova. Umožňuje dekódování, aniž by se znala délka jednotlivých slov.
- Postup: podle pravděpodobností výskytu symbolů se zdola nahoru se vytváří binární (Huffmanův) strom. Tento strom potom slouží ke generování zakódované zprávy.
- Celočíselný počet bitů na symbol.
- Nechť b je průměrný počet bitů na symbol. Potom průměrná délka kódového slova je L,

$$H(b) \leq L \leq H(b) + 1$$

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

$s_2 = 2$ 0.3

$s_1 = 1$ 0.26

$s_3 = 3$ 0.15

$s_0 = 0$ 0.12

$s_4 = 4$ 0.1

$s_5 = 5$ 0.03

$s_6 = 6$ 0.02

$s_7 = 7$ 0.02

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

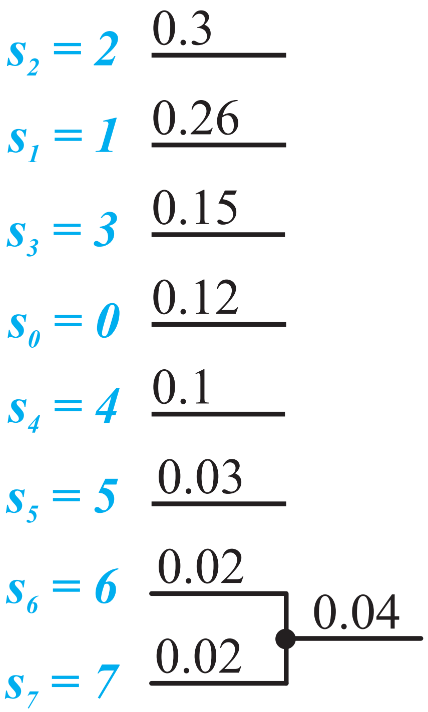

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

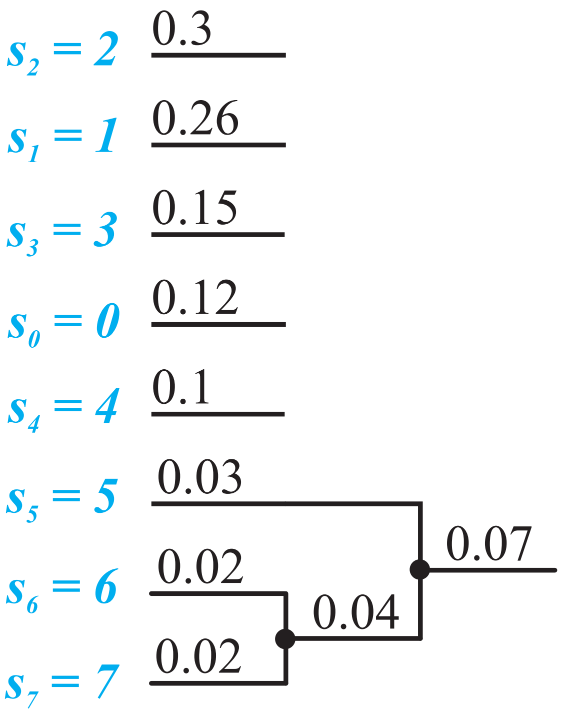

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

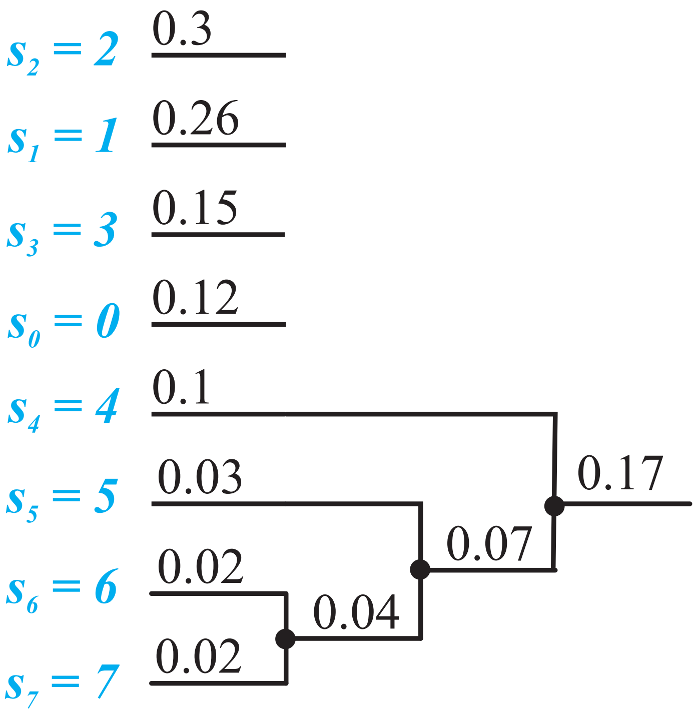

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

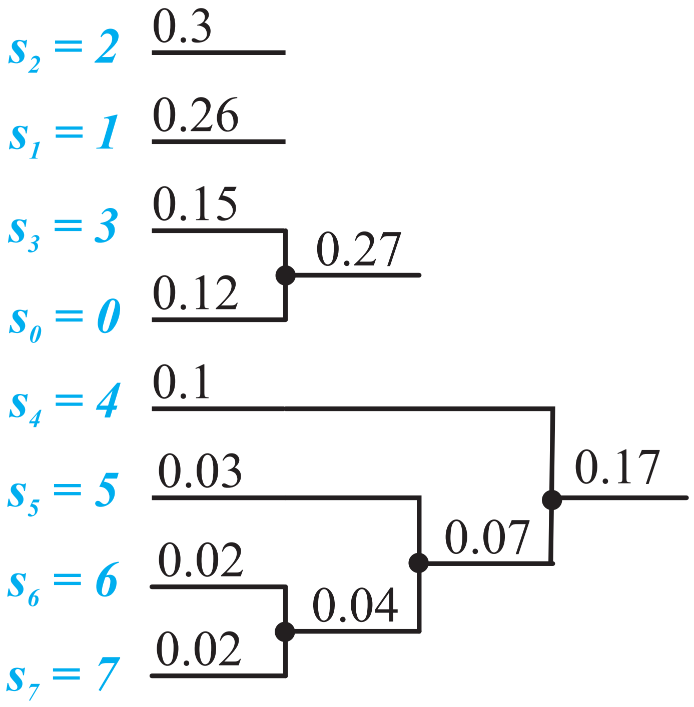

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

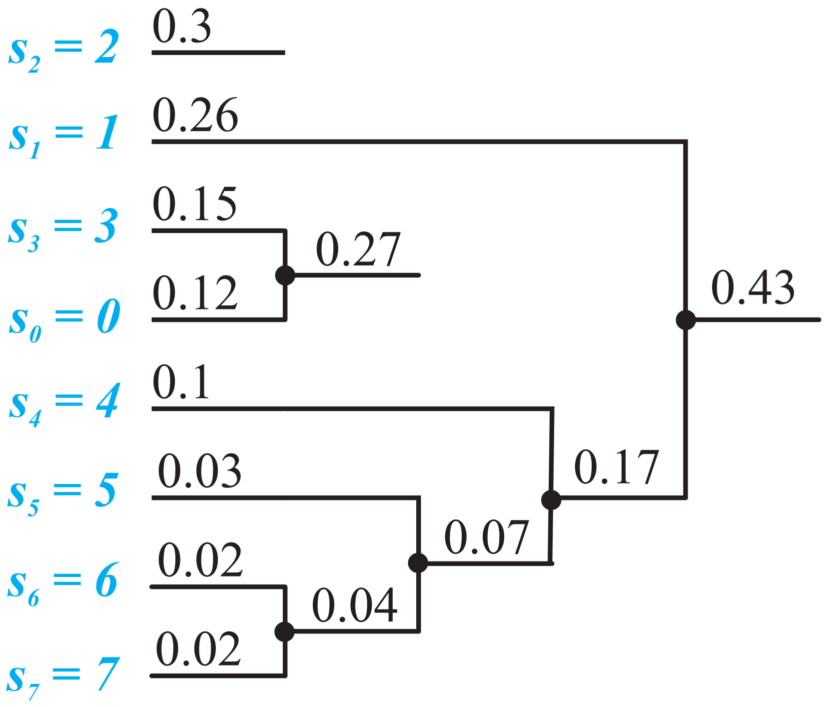

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

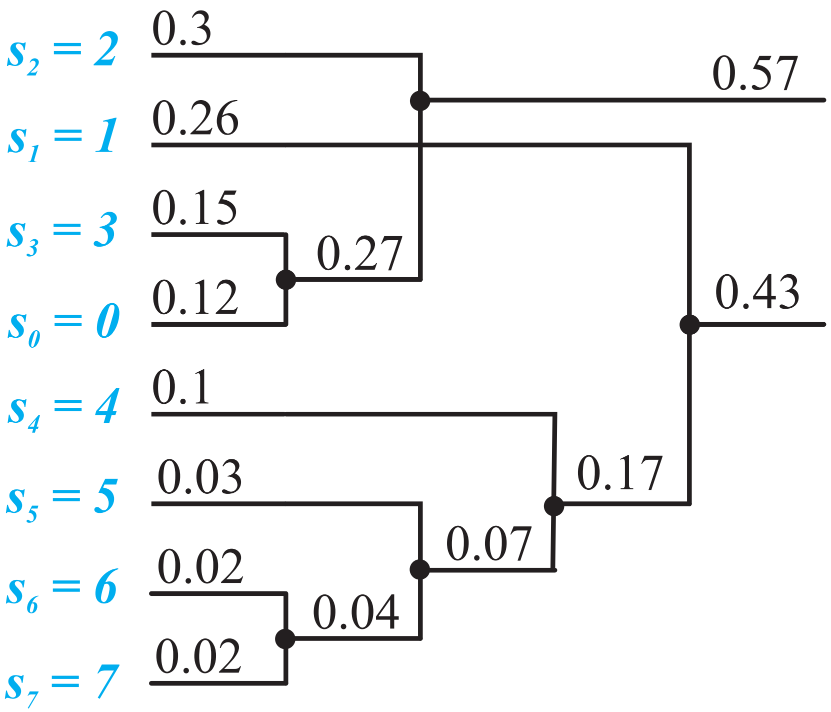

Huffmanovo kódování, příklad

Vstup: zprávy obsahují osm symbolů s pravděpodobnostmi výskytu

s_0	s_1	s_2	s_3	s_4	s_5	s_6	s_7
0.12	0.26	0.3	0.15	0.1	0.03	0.02	0.02

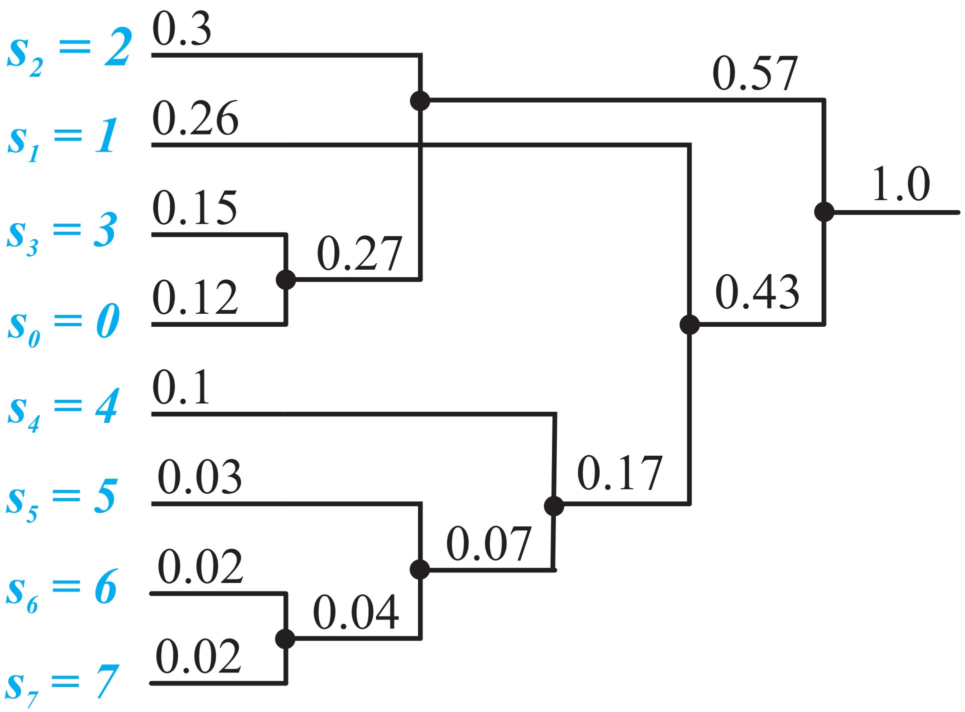

Huffmanovo kódování, příklad přeuspořádání stromu

- Důvod: aby se větve stromu nekřížily.
- Kódování: u větvení stromu 0, 1.

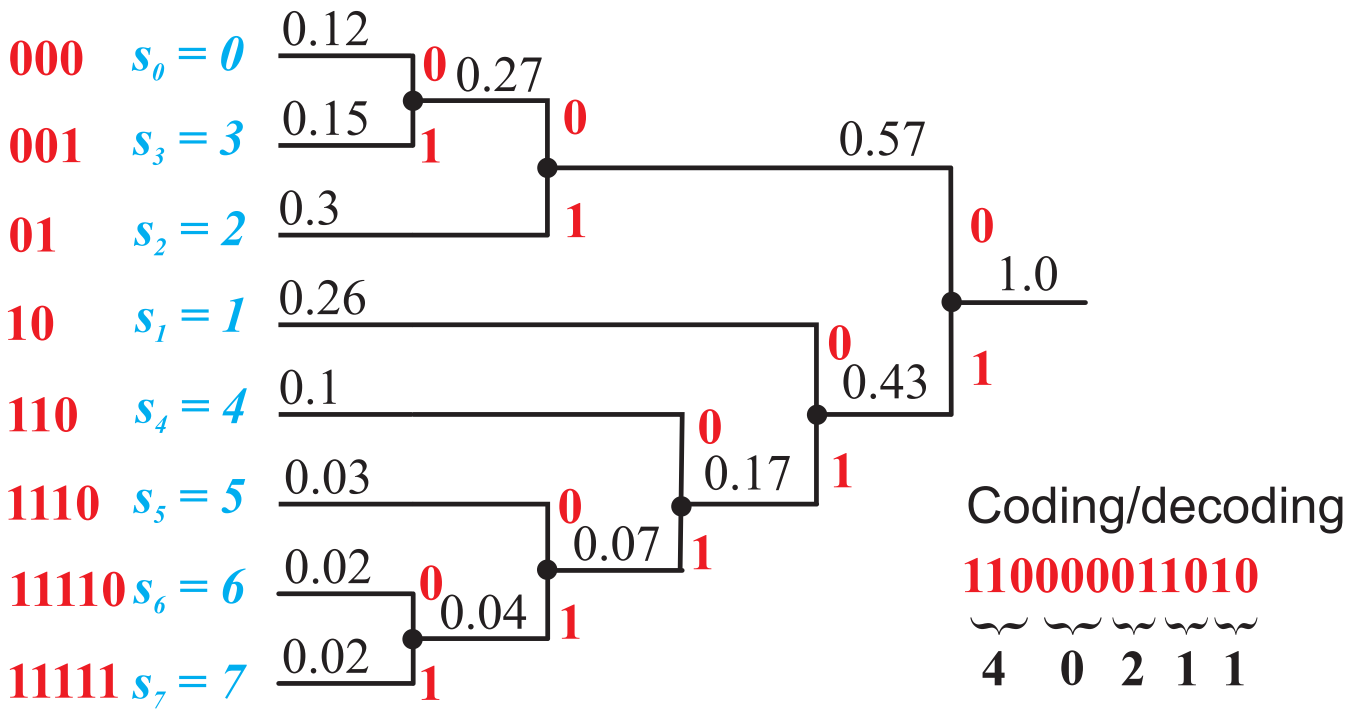

Komprese segmentovaných (interpretovaných) obrazových dat

Tytéž metody se používají pro binární obrazy, protože je lze chápat jako výsledek segmentace. Jedničky v obraze odpovídají objektům a nuly pozadí (nebo opačně).

Rozdělení metod:

- Reprezentace hranice oblasti řetězovým kódem, zvláštní případ polygonální aproximace hranice (bezeztrátová komprese).
- Aproximace hranice oblasti polygonální křivkou, také nazýváno vektorizace hranice nebo křivky (ztrátová komprese).
- Kódování oblasti úseky řádků segmentovaných oblastí (bezeztrátová komprese).
- Koutková komprese (bezeztrátová), dovoluje realizovat množinové operace a několik dalších přímo v komprimovaném tvaru. Navrhl M.I. Schlesinger v 1986, V. Hlaváč má o metodě samostatnou přednášku.

Řetězový kód hranice oblasti

- Řetězový kód (H. Freeman 1961) je zvláštní případ náhrady hranice oblasti polygonem. Jednotlivé úsečky odpovídající 4, 8, 6-sousedům mají délku 1.
- Je zadán počáteční bod hranice, např. levý horní pixel.
- Předpokládá se směr obcházení hranice proti směru hodinových ručiček.
- Rychlá implementace: vyjádří se 3×3 okolí okamžitého pixelu a řetězový kód se najde ve vyhledávací tabulce.
- Nevýhoda: řetězový kód závisí na zvoleném počátečním bodě.

4-okolí

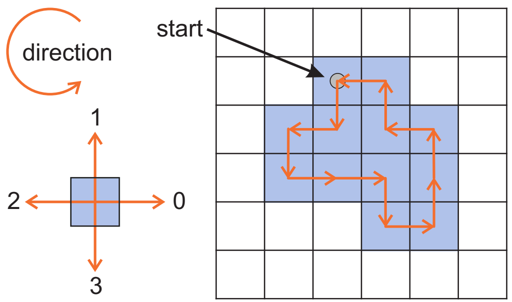

Řetězový kód: 3 2 3 0 0 3 0 1 1 2 1 2

8-okolí

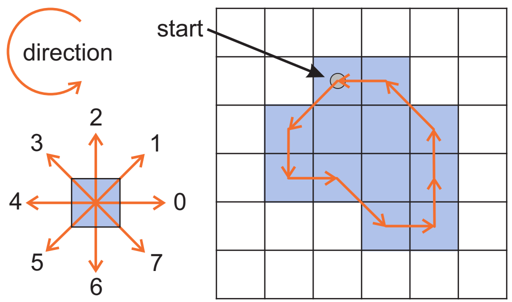

Řetězový kód: 5 6 0 7 0 2 2 3 4

Derivace dd řetězového kódu

- Derivace dd (také první diference) řetězového kódu je invariantní vůči pootočení o 90^o pro 4-okolí nebo o 45^o pro 8-okolí.
- Derivace $dd =$ počtu “kroků” pootočení proti směru hodinových ručiček pro natočení z předchozího směru d_{old} do nového směru d_{new}.

4-okolí

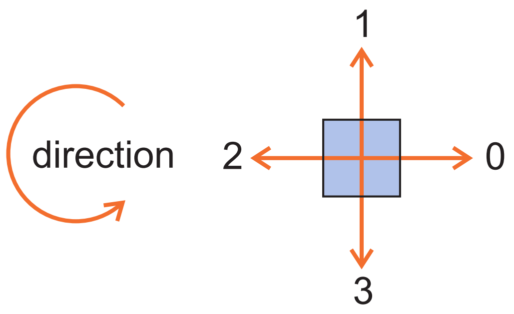

if $d_{\mathrm{new}} \geq d_{\mathrm{old}}$ then $dd = d_{\mathrm{new}} - d_{\mathrm{old}}$

if $d_{\mathrm{new}} < d_{\mathrm{old}}$ then $dd = 4 + d_{\mathrm{new}} - d_{\mathrm{old}}$

8-okolí

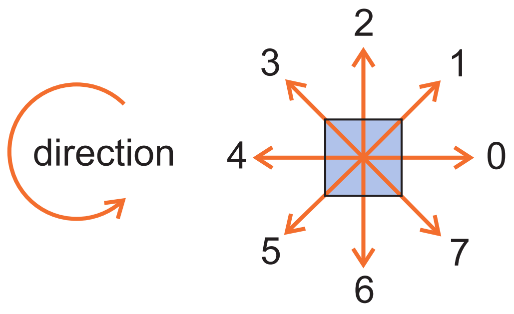

if $d_{\mathrm{new}} \geq d_{\mathrm{old}}$ then $dd = d_{\mathrm{new}} - d_{\mathrm{old}}$

if $d_{\mathrm{new}} < d_{\mathrm{old}}$ then $dd = 8 + d_{\mathrm{new}} - d_{\mathrm{old}}$

Derivace řetězového kódu dd, příklad

4-okolí

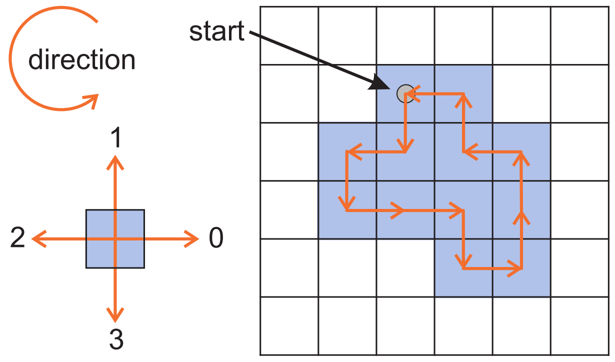

if $d_{\text{new}} \geq d_{\text{old}}$ then $dd = d_{\text{new}} - d_{\text{old}}$

if $d_{\text{new}} < d_{\text{old}}$ then $dd = 4 + d_{\text{new}} - d_{\text{old}}$

Řetězový kód: 3 2 3 0 0 3 0 1 1 2 1 2

Derivace dd: 3 1 1 0 3 1 1 0 1 3 1 1

8-okolí

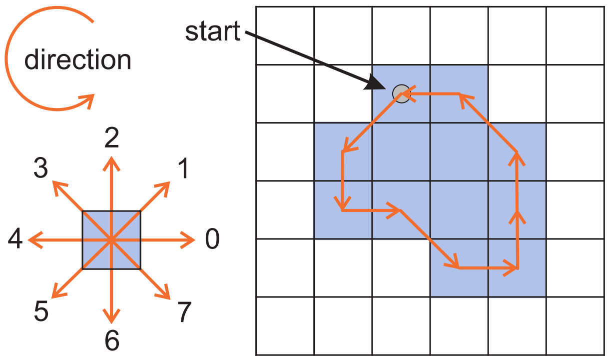

if $d_{\text{new}} \geq d_{\text{old}}$ then $dd = d_{\text{new}} - d_{\text{old}}$

if $d_{\text{new}} < d_{\text{old}}$ then $dd = 8 + d_{\text{new}} - d_{\text{old}}$

Řetězový kód: 5 6 0 7 0 2 2 3 4

Derivace dd: 1 2 7 1 2 0 1 1 1

Aproximace hranice oblasti polygonální křivkou

Ramer (1972), Douglas-Peuckerův (1973) rekurzivní algoritmus

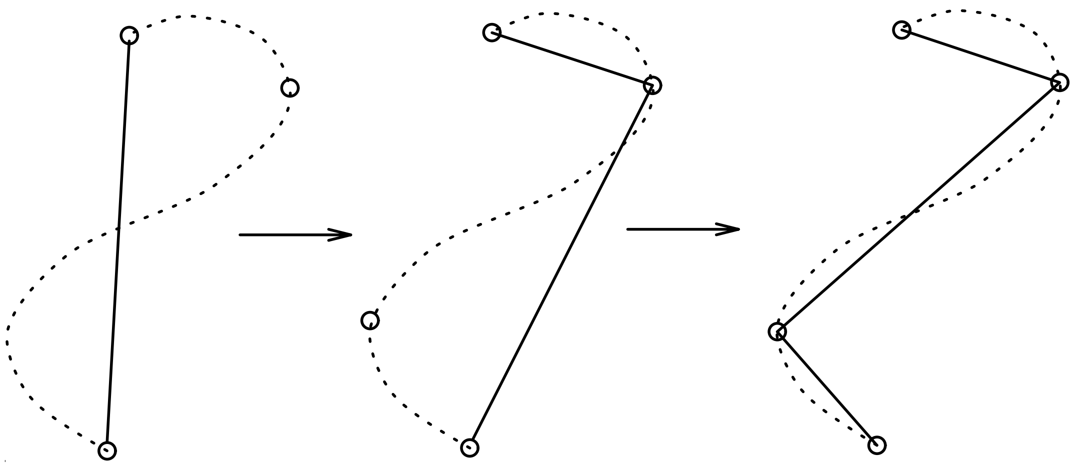

Urs Ramer: An iterative procedure for the polygonal approximation of plane curves. In Computer Graphics and Image Processing. Volume 1, Issue 3, pp. 244-256, 1972.

David Douglas, Thomas Peucker, Algorithms for the reduction of the number of points required to represent a digitized line or its caricature, The Canadian Cartographer 10(2), 112–122 (1973)

Kódování oblastí úseky řádků

- Angl. Run Length Encoding, RLE. Kódem je seznam seznamů.
- Vnější seznam obsahuje několik vnitřních seznamů. Každý z nich popisuje jeden řádek obrazu obsahující černé pixely.
- Každý vnitřní seznam popisuje jeden řádek, ale jen ty obsahující černé pixely. První prvek v seznamu je číslo řádku (v našem příkladě je modré).
- Zbývající prvky vnitřního seznamu jsou dvojice čísel. První číslo dvojice je číslo sloupce, v němž začíná spojitý úsek pixelů. Druhé číslo ve dvojici je číslo sloupce, v němž spojitý úsek končí.
- RLE používá FAX (norma CCITT Group 3).

Příklad:

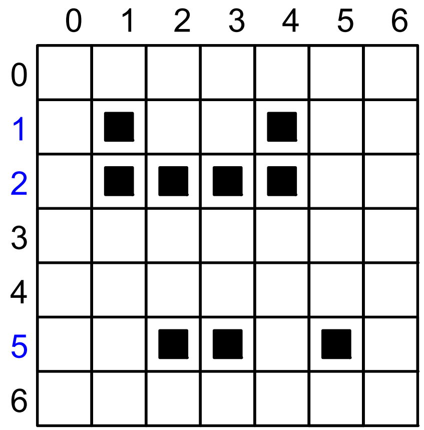

Kódování RLE:

((11144)(214)(52355))

Ztrátová komprese, rozdělení přístupů

Tři hlavní přístupy ke ztrátové kompresi obrazů:

1. Komprese dat v prostoru obrazů, tj. odstranění mnoha pixelů v obraze a vyplňování vzniklých děr pomocí doplňování angl. inpainting.
2. Použití prediktoru, který aproximuje hodnotu pixelu z několika "minulých" vzorků pixelů. Metoda bude bezeztrátová, když se s obrazem ukládá/přenáší celé reziduum $\hat{e}$. Když se celé reziduum neuchovává nebo nepřenáší. Komprese je ztrátová. Příklad: Digitální pulsně kódová modulace.
3. Komprese dat v po transformaci, např. diskrétní kosínová transformace nebo vlnková (wavelet) transformace. Data zbývající po kompresi se použijí pro rekonstrukci výchozího obrazu.

Prediktivní komprese – myšlenka

- Myšlenkou je najít matematický model dovolující predikovat hodnotu pixelu na základě několika pixelů v malém okolí.
- Ukládán/přenášen je pouze rozdíl mezi skutečnou a predikovanou hodnotou (predikční chyba) pro každý pixel a parametry modelu pro celý obrázek.
- Ke kompresi dochází, protože rozdílová data mají menší statistický rozptyl než původní data.

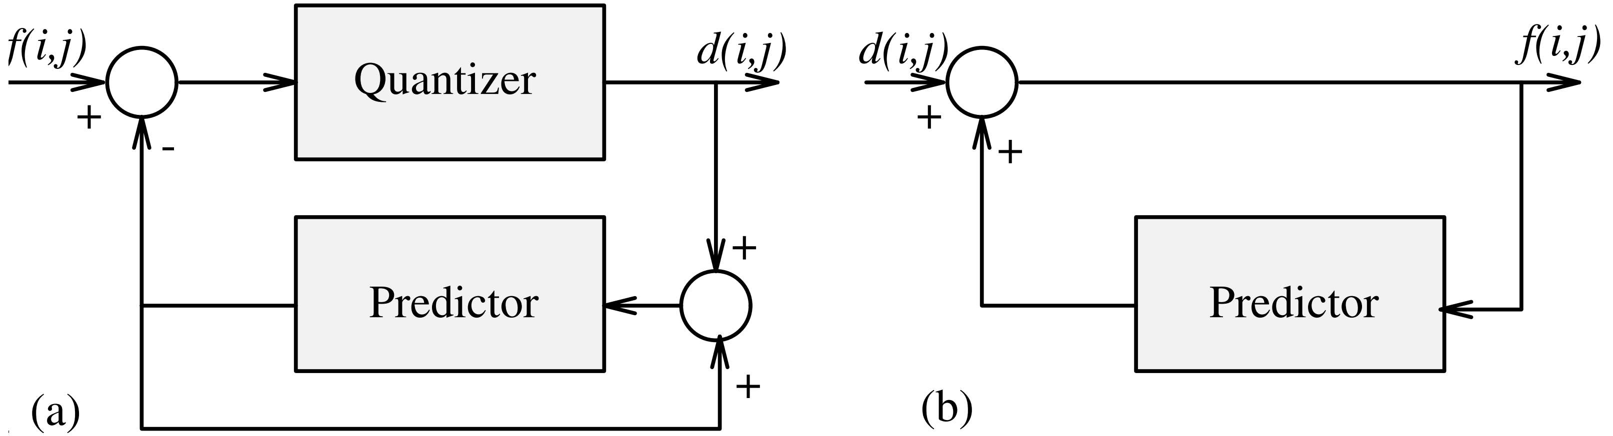

Digitální pulsně kódová modulace (1)

- Mějme obraz $f(i,j)$. Odhadněme statistické závislosti v obraze pomocí autokorelační funkce $R(i,j,k,l) = \mathcal{E}(f(i,j)\, f(k,l)) = f\, f^\top$.
- Hledáme matematický model prediktoru $\hat{f}(i,j)$.
- Rozdíl $d(i,j) = \hat{f}(i,j) - f(i,j)$.
- Předpokládejme např. lineární prediktor 3. řádu

$$\hat{f}(i,j) = a_1\, f(i,j-1) + a_2\, f(i-1,j-1) + a_3\, f(i-1,j)\ ,$$

kde a_1, a_2, a_3 jsou parametry prediktivního modelu.

$f(i,j\text{-}1)$	$f(i,j)$
$f(i\text{-}1,j\text{-}1)$	$f(i\text{-}1,j)$

Digitální pulsně kódová modulace (2)

- Jak se odhadnou parametry prediktivního modelu a_1, a_2, a_3?
- Vyřešením statistické optimalizační úlohy. Předpokládá se stacionární náhodný proces f s nulovou střední hodnotou.

$$e = \mathcal{E}\left([\tilde{f}(i,j) - f(i,j)]^2\right) .$$

a prediktor třetího řádu

$$\begin{aligned}
a_1\, R(0,0) + a_2\, R(0,1) + a_3\, R(1,1) &= R(1,0) \\
a_1\, R(0,1) + a_2\, R(0,0) + a_3\, R(1,0) &= R(1,1) \\
a_1\, R(1,1) + a_2\, R(1,0) + a_3\, R(0,0) &= R(0,1)
\end{aligned}$$

kde $R(m,n)$ je autokorelační funkce speciálního tvaru $R(\alpha,\beta) = R(0,0)\exp(-c_1\alpha - c_2\beta)$.

DPCM – Příklad, $K = 3.8$

Po rekonstrukci $K = 3.8$.

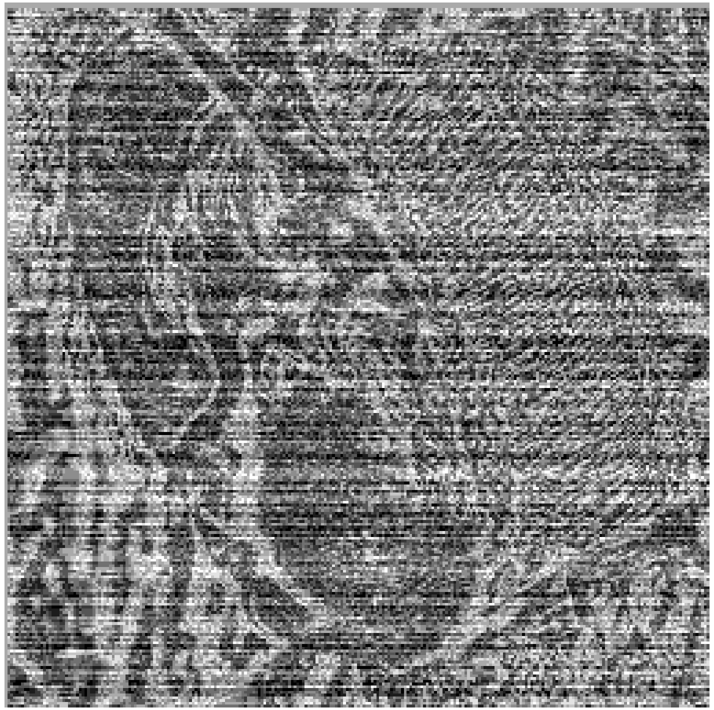

Rozdílový snímek.

DPCM – Příklad, $K = 6.2$

Po rekonstrukci $K = 6.2$.

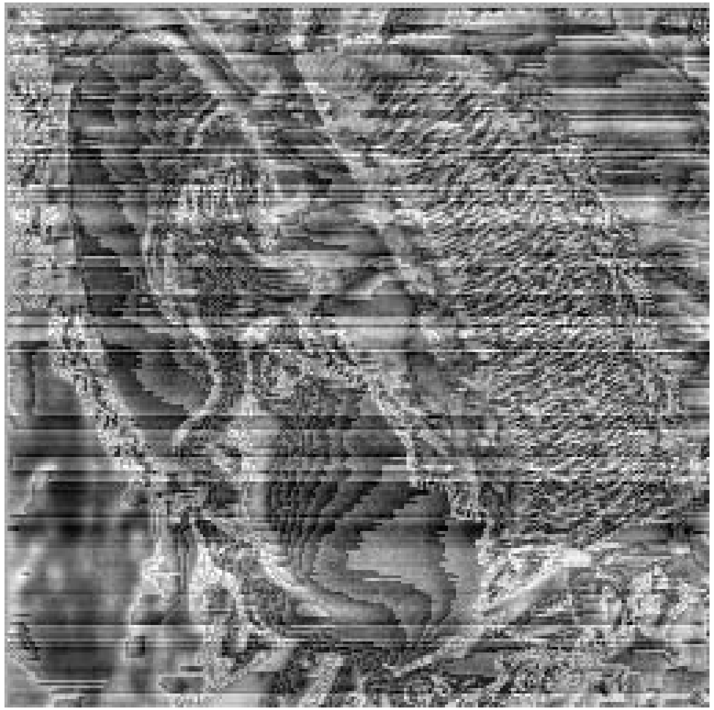

Rozdílový snímek.

JPEG, úvod

- Joint Photographic Expert Group. Standartizováno v roce 1992.
- Používá se na šedotónové i barevné obrázky. Barevné se nejdříve převedou z barevného prostoru RGB do prostoru YUV, kde lze matice U, V reprezentovat v polovičním rozlišení než matici Y ($\approx$ intenzita).
- Existuje jako ztrátová i bezeztrátová komprese.
- První generace (.jpg) z 1992 používá DCT (diskrétní kosínovou transformaci) pro odstranění redundance a irelevance. Pro optimální kódování se použije převod koeficientů DCT do 1D vektoru, kódování úseky řádků a symboly kóduje Huffmanovým kódováním.
- Druhá generace JPEG2000 (.jp2) z roku 2000 odstraňuje redundanci a irelevanci pomocí vlnkové transformace. Potom kóduje v jednotlivých bitových rovinách a symboly kóduje aritmetickým kódováním.

Proč bylo DCT zvoleno pro JPEG?

- DCT je implicitně periodická. Nejsou takové problémy s nespojitostí.
- DCT dobře aproximuje PCA (metoda hlavních směrů, Principal Component Analysis, Karhunen-Loeve rozvoj), která je optimální z hlediska středněkvadratické chyby (energie).
- Na rozdíl od PCA, DCT má pevně zvolené bázové funkce.
- Aby se ušetřil výpočetní čas, je obraz rozdělen na bloky 8×8, které jsou komprimovány nezávisle na sobě.

DCT, bázové funkce

Pevně zvolených 64 bázových funkcí.

- Každý blok obrazu 8×8 lze vyjádřit jako lineární kombinaci bázových funkcí.
- Při DCT kompresi se najde pro každý blok 64 vah lineární kombinace.
- Váhy jsou prahovány. Velikost prahu ovlivňuje míru komprese, tj. volí se požadovaná irelevance.

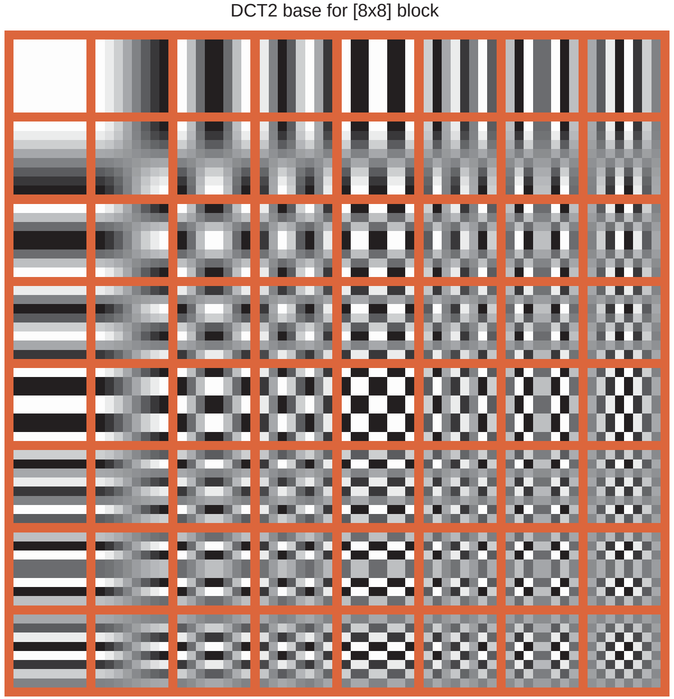

Příklad, kameraman

image block

image intensities

	1	2	3	4	5	6	7	8
1	185	187	184	183	189	186	185	186
2	185	184	186	190	187	186	189	191
3	186	187	187	188	190	185	189	191
4	186	189	189	189	193	193	193	195
5	185	190	188	193	199	198	189	184
6	191	187	162	156	116	30	15	14
7	168	102	49	22	15	11	10	10
8	25	19	19	26	17	11	10	10

Příklad, kameraman, DCT

image intensities

	1	2	3	4	5	6	7	8
1	185	187	184	183	189	186	185	186
2	185	184	186	190	187	186	189	191
3	186	187	187	188	190	185	189	191
4	186	189	189	189	193	193	193	195
5	185	190	188	193	199	198	189	184
6	191	187	162	156	116	30	15	14
7	168	102	49	22	15	11	10	10
8	25	19	19	26	17	11	10	10

coefficients of the DCT2

	1	2	3	4	5	6	7	8
1	1117	114	10	7	19	−2	−7	2
2	459	−119	−20	−11	−16	−4	3	0
3	−267	−3	24	8	1	6	4	−1
4	50	107	−9	−1	11	−6	−7	3
5	52	−111	−22	−2	−16	−2	5	−3
6	−38	39	46	19	2	0	4	3
7	−17	39	−46	−26	8	−5	−10	2
8	30	−46	28	22	−9	2	7	−1

Příklad, kameraman, 100 % a 50 %

100 % of most significant DCT2 coeffs

50 % of most significant DCT2 coeffs

Příklad, kameraman, 20 % a 5 %

20 % of most significant DCT2 coeffs

5 % of most significant DCT2 coeffs

JPEG – příklad, $K = 3.8$

Po rekonstrukci $K = 3.8$.

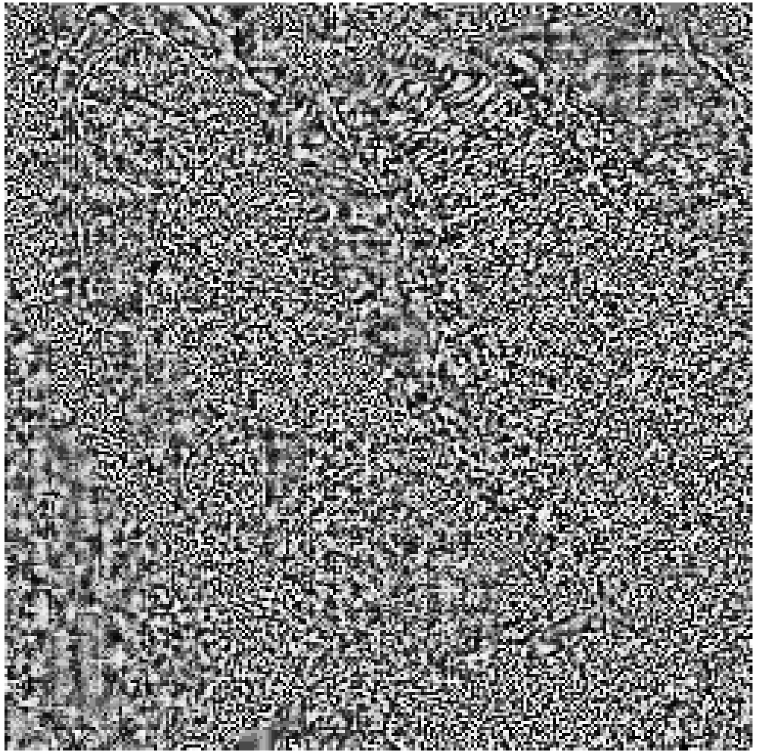

Rozdílový snímek.

JPEG – příklad, $K = 4.2$

Po rekonstrukci $K = 4.2$.

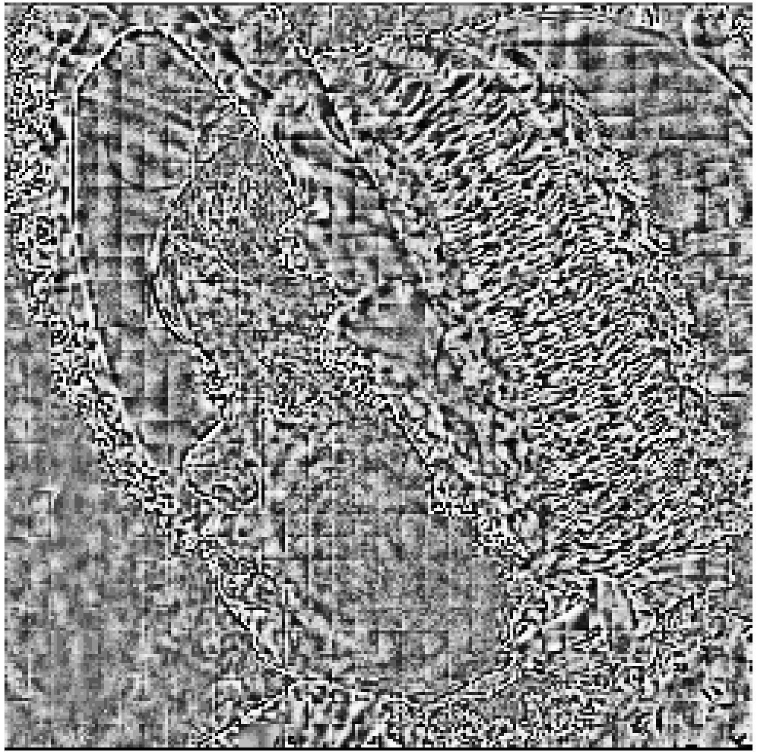

Rozdílový snímek.

JPEG – Příklad, $K = 5.6$

Po rekonstrukci $K = 5.6$.

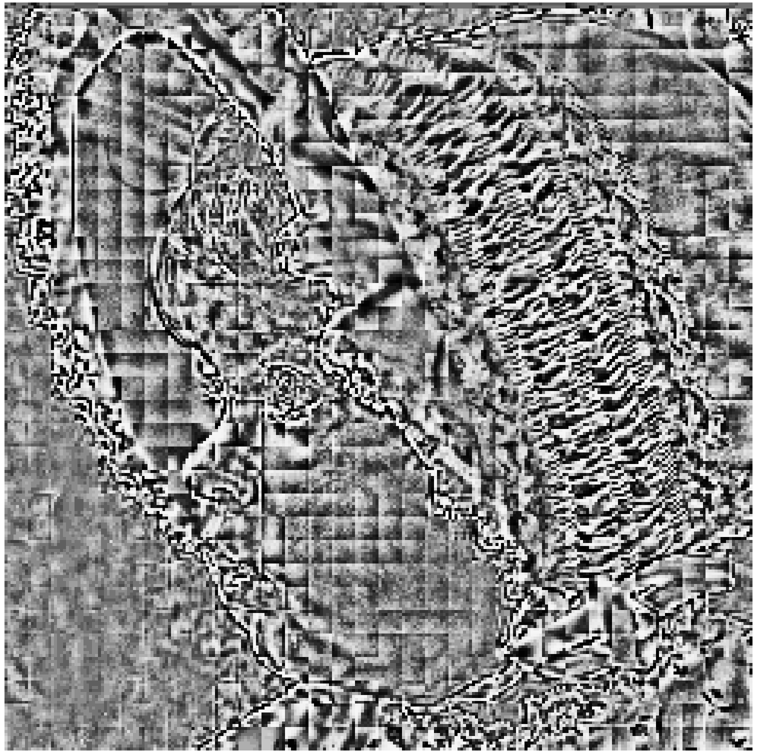

Rozdílový snímek.

JPEG – příklad, $K = 10.2$

Po rekonstrukci $K = 10.2$.

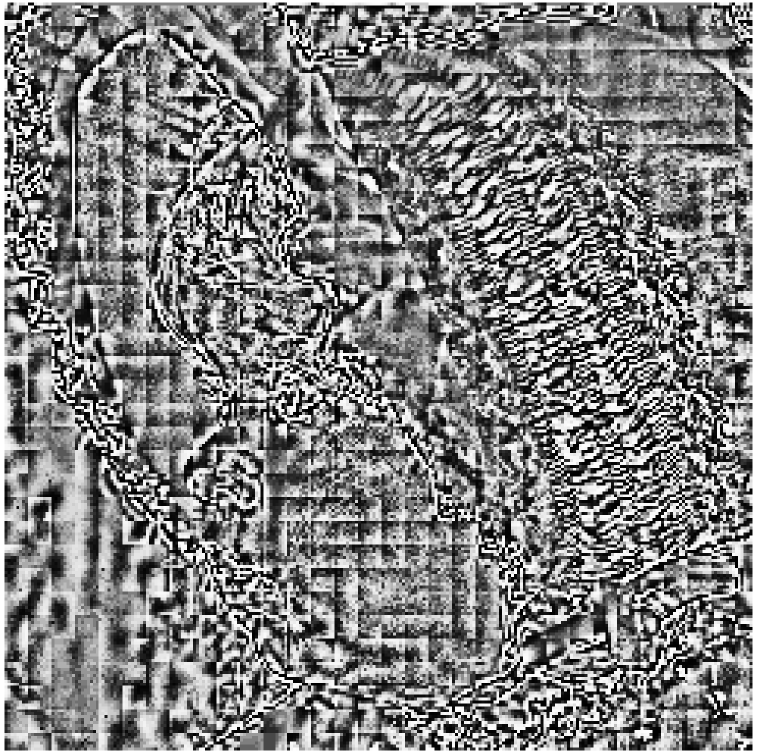

Rozdílový snímek.